

7MAI3
VÝPISKY K PÍSEMNÉ ČÁSTI ZKOUŠKY

1 VYJÁDŘENÍ PŘÍMKY VE DVOJROZMĚRNÉM PROSTORU

1.1 Explicitní tvar

$$y = ax + b$$

Proměnná a značí zkosení přímky, proměnná b posun na ose y . Explicitně nelze zapsat přímky rovnoběžné s osou y .

1.2 Implicitní tvar

$$ax + by + c = 0$$

Implicitním tvarem je možné vyjádřit všechny přímky (tj. i ty rovnoběžné s osou x).

1.3 Kanonický tvar

$$\frac{x}{u} - \frac{y}{v} = 1$$

Kanonický tvar přímky nám rovnou dává dva body přímky, a to body $(u; 0)$; $(0; v)$.

1.4 Parametrický tvar

$$x = x_1 + \vec{u} \cdot t$$

$$y = y_1 + \vec{v} \cdot t$$

Proměnné x_1 a y_1 značí souřadnice bodu (x_1, y_1) náležícího přímce, vektory $\vec{u}$ a $\vec{v}$ značí posun na příslušné ose z bodu (x_1, y_1)

2 VYJÁDŘENÍ PŘÍMKY VE TROJROZMĚRNÉM PROSTORU

Pro vyjádření přímky ve 3D využíváme pouze parametrický tvar, protože explicitní, implicitní i kanonický tvar ve tvaru, v jakém jsou zavedené, ve 3D zobrazují rovinu, nikoli přímku.

Ve 3D přidáme do kanonického tvaru třetí rovnici pro osu z se stejnými parametry jako ve 2D:

$$x = x_1 + \vec{u} \cdot t$$

$$y = y_1 + \vec{v} \cdot t$$

$$z = z_1 + \vec{w} \cdot t$$

3 DETERMINANT MATICE

3.1 Determinant pro matici 2×2

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

3.2 Determinant pro matici 3×3

$$\begin{vmatrix} a & b & c \\ d & e & f \\ g & h & i \end{vmatrix} = aei + bfg + cdh - gec - dbi - ahf$$

3.3 Determinant pro matici 4×4

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{vmatrix}$$

Postup viz [tento odkaz](#) a podkapitola Rozvoj determinantu, stejný princip se dá aplikovat i na matici 4×4 .

3.4 Determinant pro matici n×n

$$\begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{vmatrix}$$

Postup viz [tento odkaz](#) a podkapitola Zevšeobecněný rozvoj determinantu.

4 GAUSSOVA ELIMINAČNÍ METODA

Metoda používaná pro výpočet soustav lineárních rovnic. Postup viz [tento odkaz](#), podkapitola Gaussova eliminační metoda (poslední dvě strany).

5 POLYNOMIÁLNÍ INTERPOLACE

Motivací pro polynomiální interpolaci je snaha exaktně proložit sérii n bodů polynomem stupně nejvýše $n - 1$. Takovýto polynom existuje jeden jediný – to nám říká právě Vandermondův determinant:

5.1 Vandermondův determinant

Když chceme najít polynom procházející n body, řešíme soustavu n lineárních rovnic pro n neznámých, kdy hledáme neznámé koeficienty polynomu:

$$P(x) = a_0 + a_1x + a_2x^2 + \dots + a_{n-1}x^{n-1}$$

Vandermondova matice je matice sestavená z x -ových souřadnic těchto bodů. Determinant této matice říká, zda má tato soustava jedno jasné řešení. Toto – jedno jediné – řešení má právě ve chvíli, kdy jsou všechna x různá – pouze v tomto případě je její determinant je nenulový.

5.2 Lagrangeova forma interpolačního polynomu

Pro body $[x_0, y_0]$ až $[x_i, y_i]$ dosazujeme do předpisu:

$$P(x) = y_0 \frac{(x - x_1)(x - x_2) \dots (x - x_i)}{(x_0 - x_1)(x_0 - x_2) \dots (x_0 - x_i)} + y_1 \frac{(x - x_0)(x - x_2) \dots (x - x_i)}{(x_1 - x_0)(x_1 - x_2) \dots (x_1 - x_i)} + \dots + y_i \frac{(x - x_0)(x - x_2) \dots (x - x_{i-1})}{(x_i - x_0)(x_i - x_1) \dots (x_i - x_{i-1})}$$

Následně upravujeme do tvaru $a_0 + a_1x + a_2x^2 + \dots + a_{i-1}x^{i-1}$

5.3 Newtonova forma interpolačního polynomu

Pro body $[x_0, y_0]$ až $[x_i, y_i]$ dosazujeme do předpisu:

$$P(x) = v_0 + v_1(x - x_0) + v_2(x - x_0)(x - x_1) + v_3(x - x_0)(x - x_1)(x - x_2) + \dots + v_i(x - x_0)(x - x_1) \dots (x - x_{i-1})$$

Koeficienty v_i zjistíme následovně:

$$v_0 = y_0$$

$$v_1 = \frac{y_1 - v_0}{x_1 - x_0}$$

$$v_2 = \frac{y_2 - v_0 - v_1(x_2 - x_0)}{(x_2 - x_0)(x_2 - x_1)}$$

$$v_3 = \frac{y_3 - v_0 - v_1(x_3 - x_0) - v_2(x_3 - x_0)(x_3 - x_1)}{(x_3 - x_0)(x_3 - x_1)(x_3 - x_2)}$$

⋮

$$v_i = \frac{y_i - v_0 - v_1(x_i - x_0) - v_2(x_i - x_0)(x_i - x_1) - \dots - v_{i-1}(x_i - x_0)(x_i - x_1) \dots (x_i - x_{i-1})}{(x_i - x_0)(x_i - x_1)(x_i - x_2) \dots (x_i - x_{i-1})}$$

6 ALGEBRAICKÉ ŘEŠENÍ SOUSTAVY ROVNIC

6.1 Počet řešení rozšířených matic

Čtvercovou matici s nenulovým determinantem nazýváme maticí regulární.

Čtvercovou matici s nulovým determinantem nazýváme maticí singulární.

Koeficienty soustavy

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= d_1 \\a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= d_2 \\a_{31}x_1 + a_{32}x_2 + \cdots + a_{3n}x_n &= d_2 \\\vdots \\a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= d_n\end{aligned}$$

můžeme přepsat do podoby tzv. rozšířené matice, kde nalevo máme čtvercovou matici koeficientů a proměnných x , a v pravém sloupci jsou hodnoty d pravé strany:

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} & d_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & d_2 \\ a_{31} & a_{32} & \cdots & a_{3n} & d_3 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & d_n \end{pmatrix}$$

Takovou matici řešíme klasickou Gaussovou eliminační metodou.

Pojem *hodnost / rank matice* označuje počet nenulových řádků matice. Pokud je hodnost matice soustavy $M_{n \times n}$

- menší než hodnost rozšířené matice, soustava nemá řešení
- rovna hodnosti rozšířené matice a zároveň je hodnost rovna n , soustava má jedno řešení
- rovna hodnosti rozšířené matice a zároveň je ostře menší než n , soustava má nekonečně mnoho řešení $\rightarrow$ dosazujeme parametry za proměnné

6.2 Soustavy bez řešení – metoda nejmenších čtverců

Pokud máme sadu n bodů $[x_i, y_i]$, které neleží na jedné přímce, hledáme tzv. aproximační přímku. Koeficienty jejího explicitního tvaru hledáme pomocí rozšířené matice

$$\begin{pmatrix} \sum x_i^2 & \sum x_i & \sum x_i y_i \\ \sum x_i & n & \sum y_i \end{pmatrix}$$

V pravém sloupci dostaneme po úpravě Gaussovou eliminací koeficienty a a b , které dosadíme do předpisu přímky $y = ax + b$.

Odvození soustavy a detailnější popis této problematiky viz skripta nebo [tento](#) odkaz.

7 LINEÁRNÍ A AFINNÍ PROSTOR

7.1 Lineární prostor

Lineární – též vektorový – prostor je útvar (bod, přímka, rovina...), kde platí dvě pravidla:

- Lze vzít jakékoli dva objekty v tomto lineárním prostoru a sečíst je
- Lze vzít jakýkoli objekt a vynásobit jej libovolným číslem
- Má neutrální prvek (tj. prochází nulovým bodem)

Pozn.: tato definice je velmi laxní a neexaktní, pro pochopení podstaty však stačí. Přesnější definice viz skriptu.

Příklad z kolokvia – rozhodněte, které množiny kvadratických polynomů tvoří a které netvoří lineární prostor. Koeficienty A, B, C jsou libovolně zvolená reálná čísla.

- $A + Bx + Cx^2$ – jedná se o lineární prostor, jelikož po dosazení $A = B = C = 0$ dostáváme nulu (neutrální prvek)
- $Bx + Cx^2$ – opět se jedná o lineární prostor, jelikož po dosazení $B = C = 0$ dostáváme nulu (neutrální prvek)
- $1 + Bx + Cx^2$ – zde se o lineární prostor nejedná, jelikož po dosazení $B = C = 0$ zbude jednička, která není neutrálním prvkem
- $Bx + x^2$ – ani tato množina netvoří lineární prostor, protože po dosazení $B = 0$ zbude x^2 , které není neutrálním prvkem

7.2 Afinní prostor

Afinní prostor chápeme jako posunutý lineární prostor – nemá neutrální prvek.

8 SOUSTAVY SE SINGULÁRNÍ MATICÍ

Pokud má matice soustavy determinant roven nule, nazýváme ji singulární maticí. Taková soustava může mít buď žádné, nebo nekonečně mnoho řešení. V této části nás zajímá situace, kdy má soustava nekonečně mnoho řešení.

K tomu dojde tehdy, když je hodnota matice soustavy rovna hodnotě rozšířené matice, ale zároveň je menší než celkový počet neznámých.

8.1 Tvar řešení

Výsledné řešení tvoří tzv. afinní prostor (viz kapitola 7.2). Ten se vždy skládá ze dvou částí:

$$\text{řešení} = \text{partikulární řešení} + \text{lineární prostor}$$

- **Partikulární řešení (bod)** – jedno jediné konkrétní řešení původní soustavy; získáme ho tak, že za všechny volitelné parametry dosadíme nuly
- **Lineární prostor (vektory)** – reprezentuje řešení tzv. *homogenní soustavy* (tj. soustavy, která má na pravé straně samé nuly). Tento prostor tvoří vektory, které jsou násobeny zvolenými volnými parametry.

8.2 Postup výpočtu

1. Rozšířenou matici soustavy převedeme Gaussovou eliminací na trojúhelníkový tvar.
2. Ve spodní části matice nám vzniknou nulové řádky. Počet zbylých nenulových řádků udává, kolik rovnic skutečně potřebujeme.
3. Neznámé, pro které nám nezbyly rovnice, nahradíme nezávisle volitelnými parametry.
4. Zpětným dosazením vyjádříme zbylé neznámé pomocí těchto parametrů.
5. Celkový výsledek nakonec rozdělíme na část bez parametrů (partikulární řešení) a část s parametry (lineární prostor).

8.3 Příklad zápisu řešení

Mějme vyřešenou soustavu s parametry s a t , kde po úpravách dostáváme:

$$\begin{aligned}x_1 &= 6 - 1,5s - t \\x_2 &= 2 - 0,5s - 2t \\x_3 &= s \\x_4 &= t\end{aligned}$$

Výsledný afinní prostor zapíšeme vektorově takto: **bod** + **lineární prostor**

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 6 \\ 2 \\ 0 \\ 0 \end{pmatrix} + s \begin{pmatrix} -1,5 \\ -0,5 \\ 1 \\ 0 \end{pmatrix} + t \begin{pmatrix} -1 \\ -2 \\ 0 \\ 1 \end{pmatrix}$$

9 BÁZE LINEÁRNÍHO PROSTORU

Bázi lineárního prostoru můžeme chápat jako jakýsi souřadnicový systém lineárního prostoru. Je to nejmenší možná množina vektorů, pomocí kterých lze jednoznačně poskládat jakýkoliv jiný vektor v celém daném lineárním prostoru.

Počet vektorů v bázi nám zároveň udává dimenzi daného prostoru – např. prostor $\mathbb{R}^3$ má v bázi vždy přesně tři vektory.

9.1 Podmínky báze

Aby množina vektorů mohla být bází, musí splňovat dvě věci:

- Lineární nezávislost – žádný vektor z báze nemůže být lineární kombinací ostatních vektorů v bázi
- Generování prostoru – pomocí těchto vektorů musí jít vyjádřit jakýkoliv vektor v daném prostoru

9.1.1 Jak poznat bázi pomocí determinantu

Pokud je úkolem zjistit, zda n vektorů tvoří bázi v n -rozměrném prostoru, postup je následující:

1. Vektory naskládáme do sloupců matice
2. Vektory tvoří bázi právě tehdy, když je tato matice regulární, což znamená, že její determinant je nenulový
3. Pokud by vyšel determinant nula, matice je singulární, vektory jsou lineárně závislé → bázi netvoří

10 ČÍSELNÉ CHARAKTERISTIKY VEKTORŮ

Samotný lineární prostor nám dovoluje vektory pouze sčítat a natahovat. Pokud ale chceme zjistit, jak je vektor „dlouhý“ nebo jak jsou dva vektory od sebe „daleko“, potřebujeme k tomu zavést další nástroje – metriku a normu.

10.1 Metrika (vzdálenost)

Metrika, obvykle značená jako $\rho(x, y)$ nebo $d(x, y)$, je funkce, která dvěma bodům/vektorům přiřadí číslo reprezentující jejich vzdálenost. Aby něco mohlo být metrikou, musí to splňovat 4 selským rozumem odvoditelná pravidla:

1. Nezápornost – vzdálenost nikdy nemůže být záporná
2. Totožnost – vzdálenost je nulová jen a pouze tehdy, když jde o ten samý bod/vektor
3. Symetrie – z bodu A do bodu B je to stejně daleko jako z B do A
4. Trojúhelníková nerovnost – vzít to přímo je vždy nejkratší; pokud to vezmeme oklikou přes nějaký bod Z, vzdálenost bude stejná nebo delší

Mějme dva vektory, $x = (x_1, x_2, \dots, x_n)$ a $y = (y_1, y_2, \dots, y_n)$. Jejich vzdálenost spočítáme:

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$

10.2 Norma (velikost)

Zatímco metrika řeší vztah dvou vektorů, norma řeší velikost jednoho konkrétního vektoru.

Značí se podobně jako absolutní hodnota, tedy $\|x\|$. Musí splňovat tato 3 pravidla:

1. Nezápornost – velikost vektoru je vždy kladná nebo nula; nulovou velikost má jen nulový vektor
2. Škálovatelnost – když vektor zvětšíme a -krát, jeho velikost se zvětší absolutní hodnotou z a
3. Trojúhelníková nerovnost – délka součtu dvou vektorů je menší nebo rovna součtu jejich samostatných délek

Mějme vektor $x = (x_1, x_2, \dots, x_n)$. Jeho velikost spočítáme:

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

11 EUKLIDŮV PROSTOR

11.1 Euklidův prostor a skalární součin

Běžný lineární prostor nám umožňuje vektory pouze sčítat a natahovat. Abychom v něm mohli měřit úhly a určovat délky vektorů, musíme do něj zavést skalární součin. Lineární prostor s definovaným skalárním součinem se nazývá Euklidův prostor.

V praxi se nejčastěji pracuje se standardním skalárním součinem vektorů, kde se pronásobí a sečtou odpovídající složky. Mějme vektory $x = (x_1, x_2, \dots, x_n)$ a $y = (y_1, y_2, \dots, y_n)$. Jejich skalární součin zjistíme následovně:

$$\langle x, y \rangle = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

Mějme na paměti, že skalární součin je číslo a má následující vlastnosti:

- Komutativita: $\langle x, y \rangle = \langle y, x \rangle$
- Linearita: $\langle ax + by, z \rangle = a \langle x, z \rangle + b \langle y, z \rangle$
- Skalární součin vektoru sama se sebou je kladná hodnota, nulový je pouze tehdy, kdy samotný vektor je nulový

11.2 Klíčové vzorce

11.2.1 Velikost vektoru

Délka vektoru je odmocnina ze skalárního součinu vektoru se sebou samým:

$$\|x\| = \sqrt{\langle x, x \rangle} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

11.2.2 Úhel (odchylka) mezi vektory

Odvodí se ze vztahu pro skalární součin:

$$\cos \varphi = \frac{\langle x, y \rangle}{\|x\| \cdot \|y\|}$$

11.2.3 Cauchy-Schwarz-Buňakovského nerovnost

Je to zásadní vlastnost platná pro jakýkoliv skalární součin. Říká, že druhá mocnina skalárního součinu dvou vektorů je vždy menší nebo rovna součinu jejich samostatných skalárních součinů se sebou samými.

$$\langle x, y \rangle \cdot \langle x, y \rangle \leq \langle x, x \rangle \cdot \langle y, y \rangle$$

12 ORTOGONALIZACE

12.1 Ortogonalita báze

Pokud je skalární součin dvou vektorů roven nule, znamená to, že $\cos \varphi = 0$ a vektory jsou na sebe kolmé (ortogonální).

- Ortogonální báze je báze prostoru, kde jsou všechny vektory na sebe navzájem kolmé.
- Ortonormální báze je ortogonální báze, kde všechny vektory mají velikost 1.

Vyjadřování vektoru h v ortogonální bázi $f_1, \dots, f_n$ nevyžaduje složitou Gaussovu eliminaci. Souřadnice x_i získáme jednoduše pomocí skalárních součinů:

$$x_i = \frac{\langle h, f_i \rangle}{\langle f_i, f_i \rangle}$$

Mějme zadaný vektor $h = \begin{pmatrix} 3 \\ 5 \end{pmatrix}$, jehož souřadnice chceme najít v ortogonální bázi tvořené vektory $f_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ a $f_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$.

Pro výpočet první souřadnice (x_1) dosadíme do vztahu:

$$x_1 = \frac{\langle h, f_1 \rangle}{\langle f_1, f_1 \rangle} = \frac{3 \cdot 1 + 5 \cdot 1}{1 \cdot 1 + 1 \cdot 1} = \frac{8}{2} = 4$$

Druhou souřadnici (x_2) zjistíme obdobně, ve vztahu pouze upravíme indexy:

$$x_2 = \frac{\langle h, f_2 \rangle}{\langle f_2, f_2 \rangle} = \frac{3 \cdot 1 + 5 \cdot (-1)}{1 \cdot 1 + (-1) \cdot (-1)} = \frac{-2}{2} = -1$$

Výsledek: vektor h má v této ortogonální bázi souřadnice $\begin{pmatrix} 4 \\ -1 \end{pmatrix}$.

12.2 Gram-Schmidtův ortogonalizační proces

Tento algoritmus slouží k tomu, abychom z libovolné zadané báze $f_1, \dots, f_n$ vytvořili bázi ortogonální $g_1, \dots, g_n$. Každý nový krok spočívá v tom, že od původního vektoru odečteme jeho projekce do směrů již vytvořených ortogonálních vektorů.

12.2.1 Postup pro první tři vektory

První vektor opíšeme:

$$g_1 = f_1$$

Druhý vektor upravíme vůči prvnímu:

$$g_2 = f_2 - \frac{\langle f_2, g_1 \rangle}{\langle g_1, g_1 \rangle} g_1$$

Třetí vektor upravíme vůči oběma předchozím:

$$g_3 = f_3 - \frac{\langle f_3, g_1 \rangle}{\langle g_1, g_1 \rangle} g_1 - \frac{\langle f_3, g_2 \rangle}{\langle g_2, g_2 \rangle} g_2$$

12.2.2 Postup pro n-tý vektor

Pokud máme n vektorů, tak n -tý vektor upravíme:

$$g_n = f_n - \frac{\langle f_n, g_1 \rangle}{\langle g_1, g_1 \rangle} g_1 - \frac{\langle f_n, g_2 \rangle}{\langle g_2, g_2 \rangle} g_2 - \dots - \frac{\langle f_n, g_{n-1} \rangle}{\langle g_{n-1}, g_{n-1} \rangle} g_{n-1}$$

12.2.3 Ukázkový příklad ortogonalizace

Mějme zadanou neortogonální bázi tvořenou následujícími vektory:

$$f_1 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} \quad f_2 = \begin{pmatrix} 2 \\ 0 \\ -2 \end{pmatrix} \quad f_3 = \begin{pmatrix} 2 \\ 2 \\ 5 \end{pmatrix}$$

Cílem je z nich vytvořit ortogonální bázi g_1, g_2, g_3 .

Krok 1 – první vektor opíšeme a spočítáme jeho skalární součin se sebou samým

$$f_1 = g_1 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}$$

$$\langle g_1, g_1 \rangle = 1 \cdot 1 + (-1) \cdot (-1) + 0 \cdot 0 = 1 + 1 = 2$$

Krok 2 – druhý vektor zjistíme dle vztahu

$$g_2 = f_2 - \frac{\langle f_2, g_1 \rangle}{\langle g_1, g_1 \rangle} g_1$$

$$g_2 = \begin{pmatrix} 2 \\ 0 \\ -2 \end{pmatrix} - \frac{2 \cdot 1 + 0 \cdot (-1) - 2 \cdot 0}{2} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \\ -2 \end{pmatrix} - \frac{2}{2} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \\ -2 \end{pmatrix} - \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix}$$

$$\langle g_2, g_2 \rangle = 1 \cdot 1 + 1 \cdot 1 + (-2) \cdot (-2) = 1 + 1 + 4 = 6$$

Krok 3 – třetí vektor zjistíme dle vztahu

$$g_3 = f_3 - \frac{\langle f_3, g_1 \rangle}{\langle g_1, g_1 \rangle} g_1 - \frac{\langle f_3, g_2 \rangle}{\langle g_2, g_2 \rangle} g_2 = (\text{postup stejný jako u } g_2) = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix}$$

Výsledná ortogonální báze je tvořena vektory $g_1 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}, g_2 = \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix}, g_3 = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix}$

CHYBÍ ZDE POSLEDNÍ KAPITOLA, DODĚLÁM BĚHEM TÝDNE A POŠLU ODKAZ NA KOMPLETNÍ DOKUMENT